

## Сингулярное разложение (SVD)

**SVD (singular value decomposition)** – разложение, использующееся для приближения матриц матрицами заданного ранга.

Введём матрицу  $M \in R^{m \times n}$  и зададим несколько определений (заметим, что SVD разложение можно вводить и для  $M \in C^{m \times n}$  - вещественный случай рассмотрен для простоты).

### Определение:

Матрица  $A \in R^{n \times n}$  называется **ортогональной**, если  $AA^T = A^T A = I$ .

### Определение:

Неотрицательное вещественное число  $\sigma$  называется **сингулярным числом** матрицы  $M$ , тогда и только тогда, когда существуют два вектора единичной длины  $u \in R^m$  и  $v \in K^n$  такие, что:  $Mv = \sigma u$  и  $M^T u = \sigma v$ .

Такие векторы  $u$  и  $v$  называются, соответственно, **левым сингулярным вектором** и **правым сингулярным вектором**, соответствующим сингулярному числу  $\sigma$ .

### Определение:

Сингулярным разложением матрицы  $M$  является разложение следующего вида  $M = U \Sigma V^T$ , где  $\Sigma$  — матрица размера  $m \times n$ , у которой элементы, лежащие на главной диагонали — это сингулярные числа (а все элементы, не лежащие на главной диагонали, являются нулевыми), а матрицы  $U \in R^{m \times m}$  и  $V \in R^{n \times n}$  — это две ортогональные матрицы, состоящие из левых и правых сингулярных векторов соответственно.

## Метод главных компонент (PCA)

Сингулярное разложение обладает и другим интересным свойством. Оно позволяет "приближать" матрицу  $M$  некоторой матрицей  $M_k$  меньшего ранга ( $\text{rank}(M_k) = k; k \leq \text{rank}(M)$ ).

### Теорема Эккарта Янга:

Для данной матрицы  $M$  существует её аппроксимация  $M_k$  ( $\text{rank}(M_k) = k \leq \text{rank}(M)$ ) такая, что:  $\forall B \in (R^{m \times n} \cap \text{rank}(B) = k) : \|M - M_k\|_F \leq \|M - B\|_F$ , где  $\|\cdot\|_F$  - норма Фробениуса.

При этом, если элементы на диагонали матрицы  $\Sigma$  упорядочены по невозрастанию, то  $M_k = U_k \Sigma_k V_k^T$ , где  $U_k, V_k$  получаются из  $U, V$  сингулярного разложения обрезанием до  $k$  первых столбцов, а  $\Sigma_k$  получается из  $\Sigma$  - обрезанием до первых  $k$  столбцов и строк.

Рассмотрим  $x$  – одно наблюдение за  $m$  - мерным пространством и  $x'$  - его ортогональную проекцию на некоторое подпространство  $m$  - мерного пространства. Исходя из того, что проекция ортогональная:  $\|x\|^2 = \|x'\|^2 + \|x - x'\|^2$ . Теперь составим матрицы  $X$  и  $X'$  из  $n$  таких наблюдений и их ортогональных проекций и получим:  $\|X\|_F^2 = \|X'\|_F^2 + \|X - X'\|_F^2$ . Также заметим, что:  $\operatorname{argmax} \|X'\|_F = \operatorname{argmin} \|X - X'\|_F$  (в этом равенстве  $X' \in X(k)$ ,  $X$  - фиксирована, а  $X(k)$  - множество матриц ранга  $k$  со столбцами - ортогональными проекциями столбцов  $X$  на некоторое  $k$  - мерное подпространство).

Получено выражение из теоремы Эккарта-Янга. Значит для данной матрицы  $M$  на её аппроксимация из этой теоремы  $M_k$  достигается не только минимум  $\|M - M_k\|_F$ , но и максимум  $\|M_k\|_F$  среди всех матриц  $M(k)$ .

Этот факт интерпретировать так: сингулярное разложение позволяет снижать размерность признакового пространства посредством проецирования данных на некоторое подпространство, по направлениям которого сохраняется максимальный "разброс" признаков начального пространства. В этом и состоит метод главных компонент (principal component analysis).